

API Reference - IntelligenceSuite v2.1

1. Panoramica

IntelligenceSuite espone una REST API su porta 8080.

Base URL: `http://localhost:8080/api/v1`

Autenticazione via JWT Bearer Token.

2. Autenticazione

POST `/api/v1/auth/token` con `client_id` e `client_secret`.

Response: `access_token`, `expires_in` 3600 secondi.

Ruoli: `admin`, `reader`, `indexer`.

Bearer token obbligatorio in header Authorization: Bearer TOKEN.

3. Endpoint /query

POST `/api/v1/query`

Parametri: `question` (obbligatorio), `domains`, `top_k`, `min_score`.

Response: `answer`, `sources`, `confidence`, `escalated`, `latency_ms`.

Errori: 400 query vuota, 401 token scaduto, 429 rate limit.

4. Endpoint /ingest

POST `/api/v1/ingest`

Parametri: `path`, `domain` (`code|doc|auto`), `incremental`.

Response: `job_id`, `status`, `files_queued`, `estimated_seconds`.

5. Rate Limiting e SLA

Free: 100 query/giorno, 10 query/minuto.

Team: 1000 query/giorno, 100 query/minuto.

Enterprise: illimitato, 500/minuto.

SLA Enterprise: P50 < 300ms, P99 < 2000ms, uptime 99.9%, Hit@5 > 85%.